

Метод с опорни вектори (Support Vector Machine – SVM). Невронни мрежи базирани на метода с опорните вектори.

- Дискриминационно обучение на класификатори
  - Намиране с обучение на разделяща хиперравнина (граница на решението); Лесно реализуемо програмно.
  - Проблем - липсва генерално решение, няма решение ако данните не са линейно разделими (перцептрон)
- Класификатори базирани на опорни вектори (SVM)
  - Задаване и получаване на граници и обобщение. Намиране на най-правилното, вместо на първото намерено решение.
  - Обучение на линейни SVM.


# Линейна класификация

\* Задача за бинарна класификация: нека зададем класова принадлежност на изходите  $y$  зададени в интервала  $\{-1,1\}$  към входни данни  $x$

\* Линейен класификатор:  $y = \text{sign}(w \cdot x + w_0)$  като неговата 'решаваща повърхнина', т.е. разделящата хиперравнина е дефинирана с  $w \cdot x + w_0 = 0$

\* **Линейна разделимост:** Можем да намерим произволен линейен класификатор, при който да е удовлетворено условието всичките образци от обучаващата издава да бъдат правилно разпознати.

$$y_i[w \cdot x_i + w_0] > 0, \quad \forall i = 1, \dots, n$$



## Перцептрон

- При Перцептрона целта е да се намери линия разделяща входните данни на +1 и -1 класове, които да съвпадат с желания изход  $y$

$$o(x) = \text{sign}(w \cdot x + w_0) \stackrel{?}{=} y(x)$$


тогава за всеки елемент  $i$  трябва да е изпълнено

$$y_i(w \cdot x_i + w_0) > 0$$

Можем да настроим теглата  $\{w, w_0\}$  с правилото за обучение на перцептрона, което гарантира сходимост при коректно решение в случай, че имаме линейно разделими множества.


Проблем - Кое решение би ни дало най-добрата генерализация?

# Геометрична интерпретация на линеен класификатор




- Марж: минимална разлика между класовете и границите на решението.
- Отговор: Линеината повърхност на решение с максимален марж.

# Линейна класификация




## Множество решения?




Всички решения са с еднакви  
емпирични грешки, но са  
различаващи се при тестове с данни

Ами при  $w_1$ ?







Или при  $w_3$ ?




Най-сигурен вектор:  $w_2$




# Интуиция: Марж





# Геометричен марж

- Представяне с векторна алгебра



- За всеки две точки  $x_1$  и  $x_2$  лежащи на  $L$  ние имаме  $w \cdot (x_1 - x_2) = 0$ , което води до заключението, че  $w^* = w / \|w\|$  е нормалата към повърхнината  $L$ .
- За всяка точка  $x_0$  в  $L$ ,  $w \cdot x_0 = -w_0$
- Разстоянието по знак между  $x$  и  $L$  се задава с 
$$w^* \cdot (x - x_0) = \frac{1}{\|w\|} (w \cdot x + w_0)$$
- Геометричния марж на  $(x_i, y_i)$  по отношение на  $L$ : 
$$\gamma_i = y_i \frac{1}{\|w\|} (w \cdot x_i + w_0).$$
- Геометричния марж на  $\{(x_i, y_i)_{i=1}^n\}$  по отношение на  $L$ : 
$$\min_i \gamma_i.$$

## Линеен SVM Класификатор

- Линеиният SVM увеличава геометричния марж на набора от данни за обучение:

$$\begin{aligned} \max_{\mathbf{w}, w_0} \quad & C \\ \text{s.t.} \quad & y_i \frac{1}{\|\mathbf{w}\|} (\mathbf{w} \cdot \mathbf{x}_i + w_0) \geq C, \quad i = 1, \dots, n \end{aligned} \quad (1)$$

За всяко решение, отговарящо на ограниченията, всяко положително мащабирано множествено число също ги удовлетворява. Така че с произволна настройка  $\|\mathbf{w}\| = 1/C$ , е възможно да се формулира SVM като:  $(\min \|x\| \Leftrightarrow \min 1/2\|x\|^2)$

$$\begin{aligned} \min_{\mathbf{w}, w_0} \quad & \frac{1}{2} \|\mathbf{w}\|^2 \\ & y_i (\mathbf{w} \cdot \mathbf{x}_i + w_0) \geq 1, \quad i = 1, \dots, n \end{aligned} \quad (2)$$

- С тази настройка дефинираме граница около линейната граница на решение с дебелина  $1/\|\mathbf{w}\|$ .

## Решение за линейни SVM

- Можем да превърнем ограничената минимизация в неограничен проблем за оптимизация, като представим ограниченията като забранителни/наказателни членове (penalty term)

$$\min_{\mathbf{w}, w_0} \frac{1}{2} \|\mathbf{w}\|^2 + \text{penalty term}$$

За данни  $(\mathbf{x}_i, y_i)$ , може да се използва следния наказателен член.

$$\begin{cases} 0, & y_i(\mathbf{w} \cdot \mathbf{x}_i + w_0) \geq 1 \\ \infty, & \text{otherwise} \end{cases} = \max_{\alpha_i \geq 0} \alpha_i (1 - y_i[w_0 + \mathbf{w} \cdot \mathbf{x}_i])$$

Модифициране и пренаписване на процедурата за минимизация в:

$$\begin{aligned} & \min_{\mathbf{w}, w_0} \left\{ \frac{1}{2} \|\mathbf{w}\|^2 + \sum_{i=1}^n \max_{\alpha_i \geq 0} \alpha_i (1 - y_i[w_0 + \mathbf{w} \cdot \mathbf{x}_i]) \right\} \quad (3) \\ & = \min_{\mathbf{w}, w_0} \max_{\{\alpha_i \geq 0\}} \left\{ \frac{1}{2} \|\mathbf{w}\|^2 + \sum_{i=1}^n \alpha_i (1 - y_i[w_0 + \mathbf{w} \cdot \mathbf{x}_i]) \right\} \end{aligned}$$

- $\{\alpha_i\}$  се наричат мултипликатори на Лагранж

## Решение за линейни SVM

Можем да разменим 'max' и 'min':

$$\begin{aligned} & \min_{\mathbf{w}, w_0} \max_{\{\alpha_i \geq 0\}} \left\{ \frac{1}{2} \|\mathbf{w}\|^2 + \sum_{i=1}^n \alpha_i (1 - y_i [w_0 + \mathbf{w} \cdot \mathbf{x}_i]) \right\} \\ &= \max_{\{\alpha_i \geq 0\}} \min_{\mathbf{w}, w_0} \underbrace{\left\{ \frac{1}{2} \|\mathbf{w}\|^2 + \sum_{i=1}^n \alpha_i (1 - y_i [w_0 + \mathbf{w} \cdot \mathbf{x}_i]) \right\}}_{J(\mathbf{w}, w_0; \alpha)} \end{aligned} \quad (4)$$

Първо минимизираме  $J(\mathbf{w}, w_0; \alpha)$  по отношение на  $\{\mathbf{w}, w_0\}$  за всички постоянни настройки на мултипликаторите на Лагранж:

$$\frac{\partial}{\partial \mathbf{w}} J(\mathbf{w}, w_0; \alpha) = \mathbf{w} - \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i = 0 \quad (5)$$

$$\frac{\partial}{\partial w_0} J(\mathbf{w}, w_0; \alpha) = - \sum_{i=1}^n \alpha_i y_i = 0 \quad (6)$$



## Решение за линейни SVM

Замествайки (5) и (6) обратно в  $J(\mathbf{w}, w_0; \alpha)$ :

$$\begin{aligned} & \max_{\{\alpha_i \geq 0\}} \min_{\mathbf{w}, w_0} \underbrace{\left\{ \frac{1}{2} \|\mathbf{w}\|^2 + \sum_{i=1}^n \alpha_i (1 - y_i [w_0 + \mathbf{w} \cdot \mathbf{x}_i]) \right\}}_{J(\mathbf{w}, w_0; \alpha)} \quad (7) \\ &= \max_{\substack{\alpha_i \geq 0 \\ \sum_i \alpha_i y_i = 0}} \left\{ \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n y_i y_j \alpha_i \alpha_j (\mathbf{x}_i \cdot \mathbf{x}_j) \right\} \end{aligned}$$

В крайна сметка, трансформираме оригиналното линейно SVM обучение в задача за квадратично програмиране (7), който има уникално и оптимално решение.

Можем да намерим оптималните настройки за мултипликаторите на Лагранж  $\{\hat{\alpha}_i\}$  и след това да намерим оптималните тегла  $\{\hat{\mathbf{w}}, \hat{w}_0\}$ .

# Обобщение за линейните SVM

Бинарна и линейна разделяща класификация

Линеен класификатор с максимален марж между данните от отделните класове.

Обучение на SVM с минимизация на:

$$\sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i,j=1}^n y_i y_j \alpha_i \alpha_j (\mathbf{x}_i \cdot \mathbf{x}_j)$$

По отношение на  $\alpha_i \geq 0$  и  $\sum_i \alpha_i y_i = 0$ .

$$\hat{\mathbf{w}} = \sum_{i=1}^n \hat{\alpha}_i y_i \mathbf{x}_i.$$

Само една малка част от  $\hat{\alpha}_i$  ще бъдат различни от нула и съответстващите им  $\mathbf{x}_i$  се наричат опорни вектори.

Прогнозата на нов образ  $\mathbf{x}$  е знака на:

$$\hat{w}_0 + \mathbf{x} \cdot \hat{\mathbf{w}} = \hat{w}_0 + \mathbf{x} \cdot \left( \sum_{i=1}^n \hat{\alpha}_i y_i \mathbf{x}_i \right) = \hat{w}_0 + \sum_{i \in SV} \hat{\alpha}_i y_i (\mathbf{x} \cdot \mathbf{x}_i)$$

